

Ética e Governança em Inteligência Artificial

Prof. Dr. Carlos Alberto da Silva

Módulo 2 - Regulamentação da Inteligência Artificial

Unidade 2 - Gestão de riscos da IA



UFMS

AGEAD

Agência de Educação
Digital e a Distância

Nesta aula, você vai estudar...

- ❑ Dilema da Regulação vs. Inovação;
- ❑ Ciclo de Vida da IA e Responsabilidade;
- ❑ Abordagem Baseada em Risco (UE);
- ❑ Ferramentas Conformidade (Compliance); e
- ❑ Implementação Prática nas Organizações.

Motivação

- **Sustentabilidade do negócio:** conformidade jurídica
- **Confiança e reputação:** credibilidade (clientes e investidores)
 - **sistemas de IA** são seguros, auditáveis e sem *vieses*.
- **Prevenção de incidentes:** identificar e mitigar falhas.
- **Diferencial competitivo:** transformar a ética em um valor de mercado e padrão de qualidade.
- **Responsabilidade social:** garantir a justiça social.

Gestão de riscos da IA

Dilema da Regulação vs. Inovação

- A regulação deve equilibrar proteção e avanço tecnológico.
- Falta de regras gera opacidade e riscos aos consumidores.
- Gestão de risco é a resposta para um futuro sustentável.

Gestão de riscos da IA

Ciclo de Vida da IA e Responsabilidade

- A responsabilidade abrange desenvolvedores, operadores e distribuidores.
- Necessidade de vigilância em todas as etapas do software.
- Identificação de quem regula e quais direitos são protegidos.

Ética digital na Inteligência Artificial

'CICLO DE DESENVOLVIMENTO ÉTICO DE IA: DIRETRIZES DA OCDE E UNESCO'



Fonte: imagem gerada por IA (Gemini, 2026)

Gestão de riscos da IA

Conceito de Gestão de Risco

- Processo iterativo e contínuo durante toda a vida do sistema.
- Identificação e análise de riscos potenciais aos utilizadores.
- Adoção de medidas de mitigação para riscos residuais.

Abordagem Baseada em Risco (UE)

Classificação de Riscos na União Europeia

- Divisão em: Inaceitável, Alto Risco, Baixo e Mínimo.
- O rigor da gestão depende da categoria do sistema.
- Organizações devem classificar os seus sistemas precocemente.

Abordagem Baseada em Risco (UE)

Proibições de Risco Inaceitável

- Sistemas que manipulam o comportamento humano subliminarmente.
- Exploração de vulnerabilidades de grupos específicos (idade/deficiência).
- Classificação social (social scoring) por autoridades públicas.

Abordagem Baseada em Risco (UE)

Identificação de Sistemas de Alto Risco

- IA aplicada em infraestruturas críticas (água, luz, rede).
- Utilização em educação, recrutamento e gestão de trabalhadores.
- Sistemas que impactam diretamente direitos fundamentais e segurança.

Abordagem Baseada em Risco (UE)

Gestão de Risco para "Alto Risco"

- Exigência de um **sistema de gestão de riscos documentado**.
- **Testes rigorosos** para garantir precisão e robustez.
- **Monitoramento pós-introdução** no mercado para detetar desvios.

Ferramentas Conformidade (*Compliance*)

Governança de Dados e Conjuntos de Dados

- Treino de modelos com **dados de alta qualidade e relevância**.
- **Exame de possíveis enviesamentos (bias)** nos dados de entrada.
- Respeito estrito e garantias à **privacidade e proteção de dados pessoais**.

Ferramentas Conformidade (*Compliance*)

Documentação Técnica Obrigatória

- **Registo** detalhado do funcionamento e **lógica** do algoritmo.
- **Demonstração de conformidade** para autoridades fiscalizadoras.
- Facilidade e transparência da **rastreabilidade de decisões automatizadas**.

Ferramentas Conformidade (*Compliance*)

Registos Automáticos (*Logging*)

- Capacidade de **gravação de eventos** durante a operação.
- Identificação de **falhas** ou **comportamentos imprevistos** da IA.
- Garantia de **auditoria técnica** por entidades externas.

Ferramentas Conformidade (*Compliance*)

Transparência para o usuário final

- Informação clara de que o **usuário** interage com uma IA.
- Explicação sobre as **capacidades** e **limitações** do sistema.
- **Instruções precisas** para a operação segura do software.

Supervisão e Controle Humano

Supervisão Humana (*Human-in-the-loop*)

- Prevenção ou minimização de **riscos de segurança e saúde**.
- **Capacidade de humanos intervirem** em decisões da máquina.
- **Botão de paragem ou suspensão do sistema** em emergências.
- **Robustez e Cibersegurança**: resistência contra erros, falhas e tentativas de invasão, proteção contra ataques, e manutenção da precisão técnica ao longo do tempo.

Avaliação de Impacto (RIPD)

- Elaboração do **Relatório de Impacto à Proteção de Dados**.
- Análise abrangente sobre **liberdades fundamentais** dos titulares (usuários).
- Descrição de **critérios de decisão e níveis de acurácia**.
- **Medidas de mitigação de riscos**: eliminação de riscos através de *design* e desenvolvimento seguro, implementação de medidas de proteção técnica em tempo real.

Direitos dos Consumidores e Titulares

Direito à Informação e Explicação

- Consumidores têm direito a saber o "**porquê**" de uma decisão.
- **Tradução da lógica complexa** para uma linguagem acessível.
 - Fortalecimento da confiança na relação homem-máquina.
- **Salvaguardas contra discriminação**: auditorias periódicas, correção de critérios, promoção da equidade (acesso a serviços via IA).

Direitos dos Consumidores e Titulares

Direito à Contestação de Decisões

- Possibilidade de **revisão humana** para resultados automatizados.
- **Canais de reclamação diretos** para danos causados por IA.
- **Reparação de danos** em caso de falhas de responsabilidade civil.
- **Responsabilidade** do operador/distribuidor: garantia e/ou suspensão do uso, reporte de incidentes às autoridades.

Criação de Comitês de Ética em IA

- **Grupos multidisciplinares** para avaliar novos projetos de IA.
- Definição de **limites éticos** que vão além da definição da lei.
- **Alinhamento dos algoritmos** com os valores da organização.
- **Formação e conscientização interna:** treinamento das equipes em ética computacional, capacitação jurídica *compliance*, letramento em dados aos envolvidos.

Monitoramento Pós-Venda e *Feedback*

- Registro de dados sobre o **desempenho real do sistema**.
- Ajustes de modelos com base em **falhas reportadas** no uso.
- **Certificação** dos sistemas se houver mudanças substanciais.
- **Auditoria técnica e independente**: verificação, transparência, validação de algoritmos por entidades de certificação (selo de confiança) para consumidores e parceiros de negócio.

Implementação Prática nas Organizações

Papel das Autoridades de Supervisão

- **Fiscalização ativa**
 - aplicação de **multas** por incumprimento.
- Apoio às empresas através de **guias e boas práticas**.
- Promoção de *sandboxes* regulatórios para inovação segura.
 - combate a falta de transparência, investimentos em **IA explicável (XAI)**.

Pilares da IA Sustentável

- **Transparência total** sobre o funcionamento dos algoritmos de IA.
- **Proteção integral** dos direitos dos consumidores e dados.
- **Responsabilidade clara** entre todos os atores da cadeia.
- **Mecanismos de recuperação de falhas** (paradas/suspensão) de produtos e serviços.

Nesta aula, você estudou:

- ❑ A **complexa interseção** entre a governança ética e o desenvolvimento tecnológico.
- ❑ O **equilíbrio** entre o fomento à inovação e a necessidade de regulação na garantia da segurança dos sistemas de Inteligência Artificial.
- ❑ A **Abordagem Baseada em Risco** pautada na classificação dos sistemas conforme seu potencial de dano.
- ❑ As ferramentas práticas de **compliance** para a validação técnica de códigos e as metodologias de implementação.

Referências

BARBIERI, Carlos. **Governança de dados**. 1ª edição. Rio de Janeiro: Alta Books, 2020. ISBN 9788550815435.

FEFERBAUM, Marina; SILVA, Alexandre Pacheco da; COELHO, Alexandre Zavaglia; SILVEIRA, Ana Carolina Rodrigues Dias (orgs.). **Ética, governança e inteligência artificial**. 1 ed. São Paulo: Almedina, 2023. ISBN 9786556279145.

Licenciamento



Respeitadas as formas de citação formal de autores de acordo com as normas da ABNT NBR 6023 (2018), a não ser que esteja indicado de outra forma, todo material desta apresentação está licenciado sob uma [Licença Creative Commons - Atribuição 4.0 Internacional](https://creativecommons.org/licenses/by/4.0/).

