

Ética e Governança em Inteligência Artificial

Prof. Dr. Carlos Alberto da Silva

Módulo 3 - Governança em Inteligência Artificial Responsável

Unidade 2 - Estudos de casos em RAI

Nesta aula, você vai estudar:

- Alguns **casos** relacionados à **Governança** de Inteligência Artificial Responsável;
- Dimensões da **Gestão de Riscos** em RAI;
- Aspectos do **Processo de Auditoria** em RAI.

Caso baseado em Gestão de Riscos

Estudo de Caso: Telstra

- **Contexto:** líder em telecomunicações na Austrália.
- **Propósito:** construir um futuro conectado onde todos possam prosperar.
- **Desafio de Escalabilidade:** centenas de equipes no processo de desenvolvimento e operando soluções de Sistemas de IA simultaneamente.

Estudo de Caso: Telstra (Gestão de Riscos)

O Início da Jornada

- **Abordagem Inicial:** foco na criação de princípios de IA responsável de alto nível para orientar a organização.
 - **Objetivo:** definir o "porquê" e o "quê" da IA ética antes de avançar para a implementação técnica.
 - **Transição Ética:** controle prático e não princípios abstratos.
- **Princípios RAIs:** diretrizes de valores da empresa (Benefício Social, Privacidade, Segurança, Transparência e Igualdade).

Estudo de Caso: Telstra



Fonte: imagem gerada por IA (DALL-E/OpenAI, 2026)

Estudo de Caso: Telstra

Comitê de Risco (RCAID - Responsible AI Risk Committee)

- **Objetivo:** garantir o compromisso contínuo da liderança (diretoria) com a causa e princípios de RAI.
- **Função:** atuar como um fórum multidisciplinar para revisão ética e aconselhamento de projetos de alto risco em IA.
- **Composição:** especialistas em ética, jurídico, ciência de dados e riscos de negócios.

Estudo de Caso: Telstra

Governança Baseada em Riscos

- **Metodologia:** Implementação de uma estrutura que prioriza o gerenciamento de riscos ao longo de **todo o ciclo de vida**.
- **Foco:** identificação proativa de riscos éticos e técnicos antes do *deploy* (ação de ambiente Desenvolvimento $\Rightarrow$ Produção).
 - metodologias para **detectar riscos éticos** antes que o sistema seja implementado.
- **Equilíbrio:** garantir **conformidade** (*compliance*).

Estudo de Caso: Telstra


Avaliação e Classificação de Riscos

Dimensão	Descrição do risco
 Comunicações	alinhar as comunicações com o público (reputação)
 Segurança cibernética	alinhar com políticas, padrões e diretrizes de segurança
 Impacto e imparcialidade	efeito nos clientes e grupos em relação aos direitos humanos ou vulneráveis
 Jurídico	obrigações legais, regulamentares e contratuais
 Privacidade	informações pessoais, política de privacidade

Fonte: adaptado de Lu et al. (2025), imagem gerada por IA (DALL-E/OpenAI, 2026)

Estudo de Caso: Telstra

Matriz de exposição a riscos



Fonte: adaptado de Lu et al. (2025), imagem gerada por IA (DALL·E/OpenAI, 2026)

Matriz de exposição a riscos



CONSEQUÊNCIA ↑	Extremo (5)	5A
	Severo (4)	4A
	Maior (3)	3A
	Moderado (2)	2A
	Menor (1)	1A
		Raro (A)

1A	1B	1C	1D	1E
Raro (A)	Improvável (B)	Possível (C)	Provável (D)	Quase Certo (E)
PROBABILIDADE →				

Fonte: adaptado de Lu et al. (2025), imagem gerada por IA (DALL·E/OpenAI, 2026)

Estudo de Caso: Telstra

Avaliação e Estratégias de Risco

Cor	Nível / Ação Comum
 Verde	Baixo Tolerar (Aceitar o risco como está)
 Amarelo/Laranja	Médio/Alto Tratar (Mitigar/Reduzir)
 Laranja	Alto Transferir (Passar o risco para terceiros)
 Vermelho	Crítico Terminar (Eliminar a atividade que gera o risco)

Fonte: adaptado de Lu et al. (2025), imagem gerada por IA (DALL-E/OpenAI, 2026)

Estudo de Caso: Telstra

Princípios Éticos de IA da Austrália

- ❑ **No geral:** ter valor social para bem-estar humano, social e ambiental;
- ❑ **Jurídico/Privacidade:** as regulamentações sobre privacidade (proteção e segurança da privacidade);
- ❑ **Impacto humano e imparcialidade:** manter a imparcialidade, acessando todos os canais de serviço.

Práticas de Operacionalização

- **Criação de Ambientes Seguros:** ferramentas de conformidade.
- **Capacitação:** programas de treinamento (desenvolvedores e gestores) para compreender suas responsabilidades.
- **Ferramentas e *Templates*:** mecanismos de monitoramento contínuo da qualidade dos dados e dos modelos:
 - **documentação padronizada** (auditar decisões éticas).
 - **rastrear a evolução** dos sistemas IA e decisões éticas.

Estudo de Caso: Telstra

Desafios de Escalabilidade e Lições

- **Escalabilidade:** centenas de equipes sigam os padrões éticos.
- **Silos/feudos:** quebrar barreiras entre departamentos (Jurídico, Técnico e Negócios) para gerenciar volume de novos sistemas.
- **Evolução:** percepção de que a governança de IA não é estática, mas exige revisão constante conforme a tecnologia avança.
- **Educação e Cultura:** treinamento constante em RAI no trabalho de cada departamentos (Jurídico, Técnico e Negócios).

Estudo de Caso: Telstra

Futuro da Governança na Telstra

- **Evolução RCAID:** ferramentas automatizadas para monitorar.
 - **Novas Fronteiras** (agenda futura de Governança RAIs):
 - **supervisionar** novos processos incorporados para manter a eficácia em larga escala.
 - **gerenciar** os novos riscos e a oferta de novos produtos e/ou serviços na interação crescente entre sistemas de IA.
- ⇒ **Compromisso:** aprimorar os ambientes/ciclo de IA (processo).

Caso baseado em Processo de Auditoria

Estudo de Caso: Reejig

O Desafio da Gestão de Talentos

- **Problema:** dados de talentos fragmentados em "silos/feudos" organizacionais.
- **Impacto:** dificuldade em encontrar, reter e mobilizar profissionais em larga escala.
- **Solução Reejig:** uma plataforma de inteligência que agrega dados e coloca as habilidades (*skills*) em primeiro lugar.

Estudo de Caso: Reejig (Processo de Auditoria)

- **Viés na IA de talentos (prejudiciais):** não intencional e óbvio.
- **Viés de dados:** Precisão (valores corretos), Completude (não faltam atributos), Consistência (diferentes fontes), Validade (valor e tipo), Atualidade (recentes e atualizados), Exclusividade (não duplicados).

Estudo de Caso: Reejig (Processo de Auditoria)

- **Viés humano:** Estereótipo (gênero, origem, idade, etnia), Efeito manada (cognitivo), Efeito *priming* (decisão mais rápida), Seleção (amostra não aleatória), Confirmação (reforçar em acreditar).

Estudo de Caso: Reejig

Desafios da Gestão de Talentos

- **Encontrar:** localizar o talento certo (interno ou externo) instantaneamente.
- **Reter e Mobilizar:** identificar quem está pronto para o próximo passo e evitar a perda de talentos para o mercado.
- **Requalificar (*Upskill/ Reskill*):** mapear lacunas de competências e preparar a força de trabalho para o futuro.

Estudo de Caso: Reejig

O Apelo por Regulamentação

- **Cenário Global:** governos exigindo mais responsabilidade, explicabilidade e transparência em algoritmos de decisão.
- **Impacto no Recursos Humanos (RH):** ferramentas de recrutamento sem auditoria (sem conformidade) podem ser uma área de alto risco para discriminação algorítmica.
- **Resposta:** antecipação às normas de igualdade de oportunidades e Direitos Humanos.

Estudo de Caso: Reejig

Auditoria Independente e Certificação

- **Parceria estratégica:** desenvolvimento conjunto com a Universidade de Tecnologia de Sydney (UTS) no rigor científico.
 - **Inovação:** 1ª certificação de IA ética de talentos auditada.
- **Objetivo:** nova referência de confiança e transparência para a indústria.
- **Valor da Independência:** validação dos algoritmos para que operem sem preconceitos ocultos.

Estudo de Caso: Reejig

Processo de Auditoria

- **Verificação de Algoritmos:** aplicar testes rigorosos para identificar disparidades estatísticas em grupos protegidos.
- **Transparência de Dados:** garantir que a origem e o processamento das informações sejam auditáveis.
- **Governança Contínua:** fazer revisões periódicas para manter a certificação conforme o modelo evolui.

Estudo de Caso: Reejig

Redução de Vieses e Parcialidade

- **Mitigação na Origem:** como os algoritmos da Reejig são desenhados para ignorar variáveis que geram preconceitos:
 - atributos demográficos (gênero, origem, idade, etnia).
 - aplicar regulamentações globais antidiscriminação.
 - **Foco em *Skills*:** na competência técnica e comportamental, não o perfil pessoal.
- ⇒ **Equidade** de Oportunidades - Promoção da **Diversidade** (mérito)

Estudo de Caso: Reejig

Princípios-chave da IA ética

Para reduzir riscos, no desenvolvimento e uso responsável da IA:

- **Imparcialidade**, ambiente de trabalho/cultura diversificado.
- **Privacidade e segurança**, garantias e dados seguros.
- **Responsabilidade**, algoritmo auditável e resultados coerentes.
- **Transparência**, garantir decisões, combinando tecnologia e expertise humana que leva aos melhores resultados.

Estudo de Caso: Reejig

Processo de Desenvolvimento Reejig

- **RAI auditável com Design Ético** (Privacy/Ethics by Design).
- **Transparência com dados de *skills*** (apresentar estas visões aos líderes).
- ***Compliance***, sem riscos jurídicos (evitando a discriminação algorítmica).

Estudo de Caso: Reejig

Impacto e Sustentabilidade Organizacional

- **Impacto nos Negócios e na Sociedade:**
 - **Resultados Sociais:** cultura empresarial, fortalecimento marca (ética e diversidade).
- **Marca Empregadora:** usa tecnologia de forma justa.
- **Otimização da Força de Trabalho:**
 - Redução do *turnover* e aumento da eficiência operacional.
- **Benefício Social:** redução das desigualdades no mercado.

Estudo de Caso: Reejig

Visão de Futuro: *Zero Wasted Potential* (parte 1)

- **Consequências da Não-Conformidade:** riscos adicionais para organizações que ignoram a auditoria em IA.
- **Compromisso com o Bem:** uso da inteligência artificial para gerar carreiras significativas.
- **O Ideal Reejig:** um mundo onde nenhuma habilidade (*skills*) é desperdiçada por preconceito ou falta de dados.

Estudo de Caso: Reejig

Visão de Futuro: *Zero Wasted Potential* (parte 2)

- **Antecipação estratégica:** o valor de estar em conformidade antes da obrigatoriedade legal.
- **IA auditada de forma independente:**
 - não é apenas um diferencial competitivo, mas o novo padrão para empresas.
 - valorização do capital humano, sem vieses algorítmicos.

Nesta aula, você estudou...

- A **Gestão de Riscos** como um pilar nas decisões sobre Privacidade e Segurança, Transparência e Explicabilidade, Igualdade e Imparcialidade.
- O **Processo de Auditoria** contribuindo para uma visão de futuro com o *Zero Wasted Potential*.

Referências

LU, Qinghua; ZHU, Liming; WHITTLE, Jon; XU, XIWEI. **IA responsável**: melhores práticas para a criação de sistemas de IA confiáveis. 1 ed. São Paulo: Pearson, 2025. ISBN 9788543035987.

PICAZIO, Joseph Rodrigo Amorim. **Inteligência artificial e seus impactos nos direitos sociais**: um panorama da convergência e dos desafios da IA para a efetividade dos direitos e garantias fundamentais. Belo Horizonte, MG: Dialética, 2024. ISBN 9786527023326.

Licenciamento



Respeitadas as formas de citação formal de autores de acordo com as normas da ABNT NBR 6023 (2018), a não ser que esteja indicado de outra forma, todo material desta apresentação está licenciado sob uma [Licença Creative Commons - Atribuição 4.0 Internacional](https://creativecommons.org/licenses/by/4.0/).

